

统计分析方法

期末复习文档（严格按课件整理）

2026 年 2 月 22 日

面向闭卷期末：重概念、重公式、重定理证明、重“怎么用”。

目录

1 数据采集与可视化（课件第 2 章）	3
1.1 常见数据类型（2.1）	3
1.2 数据抽样方法（2.2）	3
1.3 数据初步处理（2.3）	3
1.3.1 频率分布表	3
1.3.2 样本的数字特征	3
1.4 数据的可视化（2.4）	4
2 贝叶斯统计分析（课件第 3 章）	4
2.1 基本公式：条件概率、全概率、贝叶斯公式	4
2.2 贝叶斯分类器（3.2）	5
2.3 朴素贝叶斯分类器（3.3）	5
2.3.1 参数估计与拉普拉斯修正（课件给法）	5
2.4 高斯贝叶斯分类器（3.4）	6
2.4.1 一维正态密度（课件）	6
2.4.2 多维正态密度与判别函数（课件）	6
2.4.3 三个常见协方差情形（课件结论 + 推导说明）	6
3 参数估计与假设检验（课件第 4 章）	7
3.1 统计量（4.1）	7
3.2 几个重要统计量分布（4.2）	7
3.2.1 χ^2 分布	7
3.2.2 t 分布	7
3.2.3 F 分布	7

目录	2
3.2.4 分位点记号 (课件)	7
3.3 课件定理 (必须会证、会用)	7
3.4 置信区间 (4.3)	10
3.5 假设检验 (4.4)	10
4 回归分析 (课件第 5 章)	10
4.1 回归的由来 (5.1)	10
4.2 一元线性回归模型 (5.2)	11
4.3 最小二乘估计: 正规方程与显式解 (5.2)	11
4.4 残差平方和、剩余标准差、相关指数 (课件)	12
4.5 一元线性回归的性质 (课件列出, 给出证明)	12
4.6 极大似然估计 (课件)	13
4.7 一元曲线回归 (5.3: 线性化思路)	13
4.8 多元线性回归 (5.4)	13
4.8.1 模型与矩阵形式	13
4.8.2 最小二乘估计 (课件正规方程)	14
4.8.3 多元线性回归的性质 (课件列出)	14
复习收尾清单 (建议按此自测)	14

1 数据采集与可视化 (课件第 2 章)

1.1 常见数据类型 (2.1)

- **结构化数据**: 以表格 (行/列) 为基本组织方式, 典型如关系数据库中的表。
- **非结构化数据**: 无固定表结构、形态多样, 典型如图片、音频、视频、文本等。
- **半结构化数据**: 介于两者之间, 通常有一定标签/层次结构, 典型如 XML/HTML/JSON 等。

考点速记

- 结构化/非结构化/半结构化的区分: **是否天然**是“表”; 是否具备可稳定解析的**标签结构**。

1.2 数据抽样方法 (2.2)

定义 1.1 (简单随机抽样). 要求每个个体被抽到的机会均等; 常用**抽签法**或**随机数字表法**。抽后放回为**重复抽样**, 抽后不放回为**不重复抽样**。

定义 1.2 (系统抽样 (等距抽样)). 按某种顺序排列总体个体, 设定抽样间隔 (步长), 从某一随机起点开始每隔固定间隔抽取一个个体。

定义 1.3 (分层抽样). 将总体按某特征划分为若干互不交叠的层, 每层内独立抽样, 再合并得到样本。

定义 1.4 (分级抽样 (多级抽样)). 先抽取“一级单位”, 再在每个一级单位内抽取“二级单位”, 如此多级进行。

定义 1.5 (整群抽样). 将总体分成若干群 (整群), 随机抽取若干群, 并调查被抽中群内所有个体 (或再在群内抽样)。

考点速记

- 选择抽样法的口径 (按课件): 简单随机抽样适合**个体差异较小**; 若总体存在明显差异或结构, 常用分层/分级/整群等以提高可操作性与代表性。

1.3 数据初步处理 (2.3)

1.3.1 频率分布表

1. 找出最大值与最小值;
2. 决定组距与分组数目 (组数太少估计较差, 多于 20 会增加计算麻烦);
3. 决定分点 (第一组包含最小值, 最后一组包含最大值);
4. 数出每组组频数 (**左闭右开**);
5. 计算每组组中值、组频数、组频率及累计频率。

1.3.2 样本的数字特征

设样本为 $x_1, \dots, x_n$, 将其从小到大排序为 $x_{(1)} \leq \dots \leq x_{(n)}$ 。

- 平均数: $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ 。
- 中位数: 排在正中间的 $x_{(k)}$ 称为中位数, 记作 Me 。
- 众数: 样本中出现次数最多的值。
- 极差: $R = \max x_i - \min x_i$ 。
- 样本方差: $S^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$ 。
- 样本标准差: $S = \sqrt{S^2}$ 。

考点速记

- 频率分布表的“左闭右开”、分组数 (不宜过少/过多) 是常考细节。
- 数字特征: 均值/中位数/众数/方差的定义式必须能写对。

1.4 数据的可视化 (2.4)

课件列举常见图形: 直方图、柱形图、折线图、散点图、饼图、盒形图。

2 贝叶斯统计分析 (课件第 3 章)

2.1 基本公式: 条件概率、全概率、贝叶斯公式

定义 2.1 (条件概率). 若 $P(B) > 0$, 则

$$P(A | B) = \frac{P(AB)}{P(B)}.$$

定义 2.2 (乘法公式).

$$P(AB) = P(A | B) P(B).$$

定义 2.3 (全概率公式). 设 $\{B_i\}_{i=1}^n$ 为样本空间的一个划分, 且 $P(B_i) > 0$, 则

$$P(A) = \sum_{i=1}^n P(A | B_i) P(B_i).$$

定理 2.1 (贝叶斯公式). 设 $\{B_i\}_{i=1}^n$ 为划分且 $P(B_i) > 0$, 并且 $P(A) > 0$, 则

$$P(B_i | A) = \frac{P(A | B_i) P(B_i)}{\sum_{j=1}^n P(A | B_j) P(B_j)}.$$

证明. 由条件概率与乘法公式:

$$P(B_i | A) = \frac{P(AB_i)}{P(A)} = \frac{P(A | B_i) P(B_i)}{P(A)}.$$

再由全概率公式 $P(A) = \sum_{j=1}^n P(A | B_j) P(B_j)$, 代入即得结论。□

考试提示

贝叶斯公式的**两步**：先写 $P(B_i | A) = \frac{P(AB_i)}{P(A)}$ ，再把 $P(AB_i)$ 换成 $P(A | B_i)P(B_i)$ ，最后用全概率展开 $P(A)$ 。

2.2 贝叶斯分类器 (3.2)

设类别为 $\omega_1, \dots, \omega_c$ ，观测为 x 。课件给出后验概率：

$$P(\omega_i | x) = \frac{p(x | \omega_i) P(\omega_i)}{p(x)}, \quad p(x) = \sum_{j=1}^c p(x | \omega_j) P(\omega_j).$$

贝叶斯决策规则 (课件)：选择使 $P(\omega_i | x)$ 最大的类别；等价于选择使

$$p(x | \omega_i) P(\omega_i)$$

最大的类别（因为分母 $p(x)$ 与 i 无关）。

2.3 朴素贝叶斯分类器 (3.3)

设 $x = (x_1, \dots, x_d)$ 为 d 维特征。课件采用**条件独立性假设**：

$$P(x | c) = \prod_{i=1}^d P(x_i | c).$$

因此

$$P(c | x) \propto P(c) P(x | c) = P(c) \prod_{i=1}^d P(x_i | c),$$

决策为

$$h(x) = \arg \max_c P(c) \prod_{i=1}^d P(x_i | c).$$

2.3.1 参数估计与拉普拉斯修正 (课件给法)

训练集 D ，类别集合大小为 N （课件记作类别数）。记

$$P(c) = \frac{|D_c|}{|D|}, \quad P(x_i | c) = \frac{|D_{c,x_i}|}{|D_c|}.$$

拉普拉斯修正：

$$\hat{P}(c) = \frac{|D_c| + 1}{|D| + N}, \quad \hat{P}(x_i | c) = \frac{|D_{c,x_i}| + 1}{|D_c| + N_i},$$

其中 N_i 为第 i 个特征可能取值数。

考点速记

朴素贝叶斯考试最常用“可直接套”的形式：

$$h(x) = \arg \max_c P(c) \prod_{i=1}^d P(x_i | c),$$

并能写出课件的频率估计与拉普拉斯修正 (“+1” 与分母 “+ 类别数/取值数”)。

2.4 高斯贝叶斯分类器 (3.4)

2.4.1 一维正态密度 (课件)

$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right).$$

2.4.2 多维正态密度与判别函数 (课件)

若 $x \in \mathbb{R}^d$ 且 $x | \omega_i \sim N(\mu_i, \Sigma_i)$, 则

$$p(x | \omega_i) = \frac{1}{(2\pi)^{d/2} |\Sigma_i|^{1/2}} \exp\left(-\frac{1}{2}(x - \mu_i)^\top \Sigma_i^{-1} (x - \mu_i)\right).$$

课件采用对数判别函数 (忽略与 i 无关常数)：

$$g_i(x) = \ln p(x | \omega_i) + \ln P(\omega_i) = -\frac{1}{2}(x - \mu_i)^\top \Sigma_i^{-1} (x - \mu_i) - \frac{1}{2} \ln |\Sigma_i| + \ln P(\omega_i) + \text{const.}$$

2.4.3 三个常见协方差情形 (课件结论 + 推导说明)

1. $\Sigma_i = \sigma^2 I$ (各向同性且同方差)：

$$g_i(x) = -\frac{1}{2\sigma^2} \|x - \mu_i\|^2 + \ln P(\omega_i) = w_i^\top x + w_{i0},$$

其中 $w_i = \frac{1}{\sigma^2} \mu_i$, $w_{i0} = -\frac{1}{2\sigma^2} \mu_i^\top \mu_i + \ln P(\omega_i)$, 故**线性**分类边界。

2. $\Sigma_i = \Sigma$ (共享协方差)：

$$g_i(x) = -\frac{1}{2}(x - \mu_i)^\top \Sigma^{-1} (x - \mu_i) + \ln P(\omega_i) = w_i^\top x + w_{i0},$$

其中 $w_i = \Sigma^{-1} \mu_i$, $w_{i0} = -\frac{1}{2} \mu_i^\top \Sigma^{-1} \mu_i + \ln P(\omega_i)$, 仍为**线性**边界。

3. Σ_i 各不相同：

$$g_i(x) = x^\top W_i x + w_i^\top x + w_{i0},$$

其中 $W_i = -\frac{1}{2} \Sigma_i^{-1}$, $w_i = \Sigma_i^{-1} \mu_i$, $w_{i0} = -\frac{1}{2} \mu_i^\top \Sigma_i^{-1} \mu_i - \frac{1}{2} \ln |\Sigma_i| + \ln P(\omega_i)$, 边界一般为**二次曲面** (非线性)。

证明要点

推导统一思路：从 $g_i(x) = \ln p(x | \omega_i) + \ln P(\omega_i)$ 出发，把多维正态密度代入；对指数项取对数；再展开二次型 $(x - \mu_i)^\top \Sigma_i^{-1} (x - \mu_i)$ 即可判断是线性/二次。

3 参数估计与假设检验 (课件第 4 章)

3.1 统计量 (4.1)

定义 3.1 (统计量). 设 $(X_1, \dots, X_n)$ 为总体 X 的样本, 若函数

$$T = T(X_1, \dots, X_n)$$

不依赖于总体中的未知参数, 则称 T 为该分布族的统计量。

3.2 几个重要统计量分布 (4.2)

3.2.1 χ^2 分布

定义 3.2 (χ^2 分布). 若 $X_1, \dots, X_n$ 相互独立且 $X_i \sim N(0, 1)$, 则

$$\chi^2 = X_1^2 + \dots + X_n^2 \sim \chi^2(n),$$

其中 n 为自由度。

课件给出密度 ($y > 0$):

$$f(y) = \frac{1}{2^{n/2}\Gamma(n/2)} y^{\frac{n}{2}-1} e^{-y/2}, \quad y > 0.$$

3.2.2 t 分布

定义 3.3 (t 分布). 设 $X \sim N(0, 1)$, $Y \sim \chi^2(n)$ 且独立, 则

$$T = \frac{X}{\sqrt{Y/n}} \sim t(n).$$

3.2.3 F 分布

定义 3.4 (F 分布). 设 $X \sim \chi^2(n_1)$, $Y \sim \chi^2(n_2)$ 且独立, 则

$$F = \frac{X/n_1}{Y/n_2} \sim F(n_1, n_2).$$

3.2.4 分位点记号 (课件)

- $\chi_\alpha^2(n)$: 若 $P(\chi^2 > \chi_\alpha^2(n)) = \alpha$;
- $t_\alpha(n)$: 若 $P(t > t_\alpha(n)) = \alpha$;
- $F_\alpha(n_1, n_2)$: 若 $P(F > F_\alpha(n_1, n_2)) = \alpha$ 。

3.3 课件定理 (必须会证、会用)

定理 3.1 (定理 1: 正态总体与 χ^2). 若 $(X_1, \dots, X_n)$ 为来自 $N(\mu, \sigma^2)$ 的简单样本, 则

$$\sum_{i=1}^n \frac{(X_i - \mu)^2}{\sigma^2} \sim \chi^2(n).$$

证明. 令 $Z_i = \frac{X_i - \mu}{\sigma}$, 则 $Z_i \sim N(0, 1)$ 且相互独立, 因此 $\sum_{i=1}^n Z_i^2 \sim \chi^2(n)$. 又 $\sum Z_i^2 = \sum \frac{(X_i - \mu)^2}{\sigma^2}$, 得证. $\square$

考试提示

本定理是把“未知均值 μ 先当作已知常数”进行标准化, 得到标准正态平方和。

定理 3.2 (定理 2: χ^2 的特征函数与数字特征). 若 $X \sim \chi^2(n)$, 则其特征函数

$$\varphi_X(t) = (1 - 2it)^{-n/2},$$

并且

$$\mathbb{E}X = n, \quad D(X) = 2n.$$

证明. 由密度可知 X 服从 Gamma 分布 (形状参数 $n/2$, 尺度参数 2). 其矩母函数为 $M_X(s) = (1 - 2s)^{-n/2}$ ($s < 1/2$), 故特征函数 $\varphi_X(t) = M_X(it) = (1 - 2it)^{-n/2}$. 由 $M'_X(0) = \mathbb{E}X$, $M''_X(0) = \mathbb{E}X^2$ 计算得 $\mathbb{E}X = n$, $D(X) = 2n$. $\square$

考试提示

会用: 看到 $\chi^2(n)$ 立刻写出均值 n 、方差 $2n$; 合并自由度时常配合定理 3。

定理 3.3 (定理 3: χ^2 可加性). 若 $X \sim \chi^2(n_1)$, $Y \sim \chi^2(n_2)$ 且独立, 则

$$X + Y \sim \chi^2(n_1 + n_2).$$

证明. 用特征函数: $\varphi_{X+Y}(t) = \varphi_X(t)\varphi_Y(t) = (1 - 2it)^{-n_1/2}(1 - 2it)^{-n_2/2} = (1 - 2it)^{-(n_1+n_2)/2}$, 这正是 $\chi^2(n_1 + n_2)$ 的特征函数. $\square$

定理 3.4 (定理 4: 正态总体下 $\bar{X}$ 、 S^2 与 χ^2). 设 $(X_1, \dots, X_n)$ 来自 $N(\mu, \sigma^2)$, 令

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i, \quad S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

则

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right), \quad (n-1)\frac{S^2}{\sigma^2} \sim \chi^2(n-1), \quad \text{且 } \bar{X} \text{ 与 } S^2 \text{ 相互独立}.$$

证明. 令 $Z_i = \frac{X_i - \mu}{\sigma}$, 则 $\mathbf{Z} = (Z_1, \dots, Z_n)^\top \sim N(\mathbf{0}, I_n)$. 取一个正交矩阵 A , 其第一行为 $\frac{1}{\sqrt{n}}(1, 1, \dots, 1)$, 令 $\mathbf{Y} = A\mathbf{Z}$. 则 $\mathbf{Y} \sim N(\mathbf{0}, I_n)$, 各分量独立, 且

$$Y_1 = \frac{1}{\sqrt{n}} \sum_{i=1}^n Z_i = \sqrt{n} \frac{\bar{X} - \mu}{\sigma} \sim N(0, 1).$$

又因为正交变换保长度:

$$\sum_{i=1}^n Z_i^2 = \sum_{j=1}^n Y_j^2.$$

并且

$$\sum_{i=1}^n (X_i - \bar{X})^2 = \sigma^2 \sum_{i=1}^n (Z_i - \bar{Z})^2 = \sigma^2 \sum_{j=2}^n Y_j^2,$$

其中 $\bar{Z} = \frac{1}{n} \sum Z_i$ 与 Y_1 一一对应。故

$$(n-1) \frac{S^2}{\sigma^2} = \sum_{j=2}^n Y_j^2 \sim \chi^2(n-1),$$

且 Y_1 与 $(Y_2, \dots, Y_n)$ 独立, 等价于 $\bar{X}$ 与 S^2 独立。最后 $\bar{X} \sim N(\mu, \sigma^2/n)$ 由正态线性组合得出。证毕。 $\square$

考试提示

定理 4 是整章核心: “均值正态、方差卡方、且独立”, 直接生成 t 检验与 F 检验。

定理 3.5 (定理 5: t 分布的来源). 设 $(X_1, \dots, X_n)$ 来自 $N(\mu, \sigma^2)$, 则

$$\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1).$$

证明. 由定理 4, $Z = \sqrt{n} \frac{\bar{X} - \mu}{\sigma} \sim N(0, 1)$, $U = (n-1) \frac{S^2}{\sigma^2} \sim \chi^2(n-1)$, 且 $Z \perp U$ 。于是

$$\frac{\bar{X} - \mu}{S/\sqrt{n}} = \frac{Z}{\sqrt{U/(n-1)}} \sim t(n-1).$$

$\square$

定理 3.6 (定理 6: F 分布的来源 (两正态总体方差比)). 若 $(X_1, \dots, X_{n_1})$ 来自 $N(\mu_1, \sigma_1^2)$, $(Y_1, \dots, Y_{n_2})$ 来自 $N(\mu_2, \sigma_2^2)$, 两样本独立, 则

$$\frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F(n_1-1, n_2-1),$$

其中 S_1^2, S_2^2 为各自样本方差。

证明. 由定理 4,

$$U_1 = (n_1-1) \frac{S_1^2}{\sigma_1^2} \sim \chi^2(n_1-1), \quad U_2 = (n_2-1) \frac{S_2^2}{\sigma_2^2} \sim \chi^2(n_2-1),$$

且相互独立。于是

$$\frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} = \frac{U_1/(n_1-1)}{U_2/(n_2-1)} \sim F(n_1-1, n_2-1).$$

$\square$

定理 3.7 (定理 7: 两正态总体均值差的 t 分布 (等方差)). 设两独立样本分别来自 $N(\mu_1, \sigma^2)$ 与 $N(\mu_2, \sigma^2)$, 样本量 n_1, n_2 , 样本均值 $\bar{X}, \bar{Y}$, 令合并方差

$$S_w^2 = \frac{(n_1-1)S_1^2 + (n_2-1)S_2^2}{n_1 + n_2 - 2}.$$

则

$$\frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t(n_1 + n_2 - 2).$$

证明. 由正态独立样本性质, $\bar{X} - \bar{Y}$ 为正态, 且

$$Z = \frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sigma \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim N(0, 1).$$

同时由定理 4 在两样本上分别成立并独立, 可得

$$U = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{\sigma^2} \sim \chi^2(n_1 + n_2 - 2),$$

且 $Z \perp U$. 注意 $S_w^2 = \sigma^2 \cdot \frac{U}{n_1 + n_2 - 2}$, 于是目标统计量为

$$\frac{Z}{\sqrt{U/(n_1 + n_2 - 2)}} \sim t(n_1 + n_2 - 2).$$

□

3.4 置信区间 (4.3)

定义 3.5 (置信区间). 若随机区间 $(\theta_L(X), \theta_U(X))$ 满足

$$P_\theta\{\theta_L(X) < \theta < \theta_U(X)\} = 1 - \alpha,$$

则称其为参数 θ 的**置信度**为 $1 - \alpha$ 的置信区间。

课件还给出单侧形式: 如 $P_\theta\{\theta \leq T\} = 1 - \alpha$, 则 $(-\infty, T]$ 为**置信度** $1 - \alpha$ 的单侧置信区间, T 为置信上限 (另一个方向同理)。

考点速记

置信区间的“定义句”要会写: **概率为 $1 - \alpha$ 覆盖真参数。**

3.5 假设检验 (4.4)

定义 3.6 (假设检验问题). 设统计模型 $\{P_\theta, \theta \in \Theta\}$. 关于参数的推测 $H: \theta \in \Theta_0 \subset \Theta$ 称为假设. 常涉及两假设: 原假设 H_0 与备择假设 H_1 , 构成假设检验问题:

$$H_0: \theta \in \Theta_0, \quad H_1: \theta \in \Theta_1.$$

课件例: 检验砖厂抗断强度均值是否为 32.50 ($\alpha = 0.05$):

$$H_0: \mu = 32.50, \quad H_1: \mu \neq 32.50.$$

4 回归分析 (课件第 5 章)

4.1 回归的由来 (5.1)

回归一词源于 Galton 的“子代身高向平均值靠拢”的发现; 随后 Pearson 等进一步证实 (课件叙述)。

4.2 一元线性回归模型 (5.2)

定义 4.1 (一元线性回归模型 (课件)). 随机变量 y 与普通变量 x 的关系为

$$y = a + bx + \varepsilon,$$

其中 x 为可控 (或可观察) 的非随机变量 (自变量/预报变量), ε 为不可观察随机误差, 满足

$$\mathbb{E}(\varepsilon) = 0, \quad D(\varepsilon) = \sigma^2 < +\infty,$$

且 a, b, σ^2 为未知参数, 与 x 无关。

于是

$$\mathbb{E}(y) = a + bx.$$

4.3 最小二乘估计: 正规方程与显式解 (5.2)

给定样本点 (x_i, y_i) , 经验回归直线记作

$$\hat{y} = \hat{a} + \hat{b}x.$$

课件采用**最小二乘法**: 最小化误差平方和

$$Q(a, b) = \sum_{i=1}^n (y_i - a - bx_i)^2.$$

定理 4.1 (一元线性回归的最小二乘解). 令

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \quad \bar{y} = \frac{1}{n} \sum_{i=1}^n y_i,$$

$$L_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i^2 - n\bar{x}^2, \quad L_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = \sum_{i=1}^n x_i y_i - n\bar{x}\bar{y}.$$

则使 $Q(a, b)$ 最小的解为

$$\hat{b} = \frac{L_{xy}}{L_{xx}}, \quad \hat{a} = \bar{y} - \hat{b}\bar{x}.$$

证明. 对 $Q(a, b)$ 分别对 a, b 求偏导并令其为 0:

$$\frac{\partial Q}{\partial a} = -2 \sum_{i=1}^n (y_i - a - bx_i) = 0, \quad \frac{\partial Q}{\partial b} = -2 \sum_{i=1}^n x_i (y_i - a - bx_i) = 0.$$

得到正规方程

$$\sum_{i=1}^n y_i = na + b \sum_{i=1}^n x_i, \quad \sum_{i=1}^n x_i y_i = a \sum_{i=1}^n x_i + b \sum_{i=1}^n x_i^2.$$

用 $\bar{x}, \bar{y}$ 消元可得 $\hat{b} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} = \frac{L_{xy}}{L_{xx}}$, 再代回得 $\hat{a} = \bar{y} - \hat{b}\bar{x}$. □

考点速记

一元线性回归 “必背三件套”: L_{xx} 、 L_{xy} 、 $\hat{b} = L_{xy}/L_{xx}$, 以及 $\hat{a} = \bar{y} - \hat{b}\bar{x}$ 。

4.4 残差平方和、剩余标准差、相关指数 (课件)

课件记

$$Q = \sum_{i=1}^n (y_i - \hat{y}_i)^2, \quad S = \sqrt{\frac{Q}{n-2}},$$

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = 1 - \frac{Q}{L_{yy}}, \quad L_{yy} = \sum_{i=1}^n (y_i - \bar{y})^2.$$

4.5 一元线性回归的性质 (课件列出, 给出证明)

性质 4.1 (性质 1 (课件)). $\hat{a}, \hat{b}$ 是 a, b 的线性无偏估计, 并且

$$\text{Cov}(\bar{y}, \hat{b}) = 0, \quad \text{Cov}(\hat{a}, \hat{b}) = -\frac{\bar{x}}{L_{xx}}\sigma^2,$$

$$D(\hat{a}) = \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{L_{xx}} \right), \quad D(\hat{b}) = \frac{\sigma^2}{L_{xx}}.$$

证明. 模型为 $y_i = a + bx_i + \varepsilon_i$, 其中 $\mathbb{E}\varepsilon_i = 0$, $D(\varepsilon_i) = \sigma^2$, 且误差相互不相关 (按课件 “随机误差” 设定的常用口径)。将 $\hat{b}$ 写成线性形式:

$$\hat{b} = \frac{\sum (x_i - \bar{x})y_i}{L_{xx}} = \frac{\sum (x_i - \bar{x})(a + bx_i + \varepsilon_i)}{L_{xx}} = b + \frac{\sum (x_i - \bar{x})\varepsilon_i}{L_{xx}},$$

因为 $\sum (x_i - \bar{x}) = 0$ 且 $\sum (x_i - \bar{x})x_i = L_{xx}$ 。故 $\mathbb{E}(\hat{b}) = b$, 并且

$$D(\hat{b}) = \frac{1}{L_{xx}^2} D\left(\sum (x_i - \bar{x})\varepsilon_i\right) = \frac{1}{L_{xx}^2} \sum (x_i - \bar{x})^2 \sigma^2 = \frac{\sigma^2}{L_{xx}}.$$

又 $\hat{a} = \bar{y} - \hat{b}\bar{x}$, 且 $\mathbb{E}(\bar{y}) = a + b\bar{x}$, 所以 $\mathbb{E}(\hat{a}) = a$ (无偏)。此外

$$D(\bar{y}) = D\left(\frac{1}{n} \sum \varepsilon_i\right) = \frac{\sigma^2}{n},$$

并可计算

$$\text{Cov}(\bar{y}, \hat{b}) = \text{Cov}\left(\frac{1}{n} \sum \varepsilon_i, \frac{1}{L_{xx}} \sum (x_i - \bar{x})\varepsilon_i\right) = \frac{1}{nL_{xx}} \sum (x_i - \bar{x}) D(\varepsilon_i) = 0,$$

因为 $\sum (x_i - \bar{x}) = 0$ 。于是

$$D(\hat{a}) = D(\bar{y} - \bar{x}\hat{b}) = D(\bar{y}) + \bar{x}^2 D(\hat{b}) - 2\bar{x} \text{Cov}(\bar{y}, \hat{b}) = \frac{\sigma^2}{n} + \bar{x}^2 \frac{\sigma^2}{L_{xx}},$$

并且

$$\text{Cov}(\hat{a}, \hat{b}) = \text{Cov}(\bar{y} - \bar{x}\hat{b}, \hat{b}) = \text{Cov}(\bar{y}, \hat{b}) - \bar{x} D(\hat{b}) = -\bar{x} \frac{\sigma^2}{L_{xx}}.$$

证毕。 □

性质 4.2 (性质 2 (课件)). $S^2 = \frac{Q}{n-2}$ 是 σ^2 的无偏估计 (课件: $S = \sqrt{Q/(n-2)}$).

证明. 将残差写为 $e_i = y_i - \hat{y}_i$, 则 $Q = \sum e_i^2$. 一元线性回归中估计了两个参数 a, b , 有效自由度为 $n-2$. 在误差满足 $\mathbb{E}\varepsilon_i = 0$, $D(\varepsilon_i) = \sigma^2$ 且不相干的常用条件下, 可推出 $\mathbb{E}(Q) = (n-2)\sigma^2$, 因此 $\mathbb{E}(\frac{Q}{n-2}) = \sigma^2$, 即无偏. $\square$

考试提示

性质 1 给出“方差/协方差”的直接结论, 常用于写出估计量的离散程度; 性质 2 解释了为什么分母是 $n-2$.

4.6 极大似然估计 (课件)

课件指出: 若进一步假设 $\varepsilon \sim N(0, \sigma^2)$ (并独立), 则可求 a, b 的极大似然估计。

说明. 因为正态似然的对数似然 (忽略常数) 为 $-\frac{1}{2\sigma^2} \sum (y_i - a - bx_i)^2$, 所以最大化似然等价于最小化 $Q(a, b)$, 因此 MLE 与最小二乘解一致。

4.7 一元曲线回归 (5.3: 线性化思路)

课件的核心做法: 通过变量变换把曲线回归转成线性回归, 再使用一元线性回归的全套公式。

- 课件例: 双曲线

$$\frac{1}{y} = a + \frac{b}{x}.$$

令 $u = \frac{1}{y}$, $v = \frac{1}{x}$, 则线性化为

$$u = a + bv,$$

对样本点 (u_i, v_i) 做一元线性回归, 得到 $\hat{u} = \hat{a} + \hat{b}v$, 再还原为

$$\frac{1}{\hat{y}} = \hat{a} + \hat{b}\frac{1}{x}.$$

考点速记

曲线回归考法通常是: 识别可线性化形式 $\rightarrow$ 定义新变量 $\rightarrow$ 套用一元线性回归求 $\hat{a}, \hat{b}$, 最后还原回原变量。

4.8 多元线性回归 (5.4)

4.8.1 模型与矩阵形式

设响应变量 y 与 p 个自变量 $(x_1, \dots, x_p)$:

$$y = a_0 + a_1x_1 + \dots + a_px_p + \varepsilon, \quad \mathbb{E}(\varepsilon) = 0, D(\varepsilon) = \sigma^2.$$

写成矩阵形式:

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon},$$

其中 $\boldsymbol{\beta} = (a_0, a_1, \dots, a_p)^\top$, $\mathbf{X}$ 为设计矩阵 (第一列为全 1, 其余列为各自变量观测)。

4.8.2 最小二乘估计 (课件正规方程)

定义误差平方和

$$Q(\beta) = (Y - X\beta)^T(Y - X\beta).$$

令偏导为 0 得到正规方程

$$X^T X \beta = X^T Y.$$

若 $X^T X$ 可逆, 则

$$\hat{\beta} = (X^T X)^{-1} X^T Y.$$

4.8.3 多元线性回归的性质 (课件列出)

课件给出 (此处按课件列式; 证明口径与一元回归类似):

- 性质 1: $\hat{\beta}$ 使 $Q(\beta)$ 达到最小;
- 性质 2: $\hat{\beta}$ 是 β 的线性无偏估计;
- 性质 3: 离差平方和分解: $L_{yy} = U + Q$ (回归平方和 U 、残差平方和 Q);
- 性质 4: $\hat{\beta}$ 是 β 的最好线性无偏估计 (协方差阵最小);
- 性质 5: $\text{Cov}(\hat{\beta}, e) = 0$ (与残差不相关);
- 性质 6: σ^2 的无偏估计

$$\hat{\sigma}^2 = \frac{Q}{n - p - 1} = \frac{e^T e}{n - p - 1};$$

- 性质 7: 若再加正态假设 $\varepsilon \sim N(0, \sigma^2 I)$, 则 $\hat{\beta}$ 也是 β 的极大似然估计 (课件给出 UMVUE 结论)。

证明要点

- 性质 1: 由 $Q(\beta)$ 为凸二次型, 解正规方程即全局最小。
- 性质 2: $\hat{\beta} = (X^T X)^{-1} X^T (Y) = \beta + (X^T X)^{-1} X^T \varepsilon$, 取期望得无偏。
- 性质 6: 有效自由度为 $n - (p + 1) = n - p - 1$, 并且 $\mathbb{E}(Q) = (n - p - 1)\sigma^2$ (与一元回归同理)。

考点速记

多元回归最核心就两行:

$$X^T X \beta = X^T Y, \quad \hat{\beta} = (X^T X)^{-1} X^T Y,$$

以及方差估计

$$\hat{\sigma}^2 = \frac{Q}{n - p - 1}.$$

复习收尾清单 (建议按此自测)

1. 能默写: 条件概率、全概率、贝叶斯公式; 朴素贝叶斯决策式与拉普拉斯修正。
2. 能写出并解释: $\chi^2/t/F$ 的定义与分位点符号含义。
3. 能完整证明: 课件定理 1-7 (尤其定理 4 的“正交变换/独立性”思路)。
4. 会写置信区间定义 (概率覆盖 $1 - \alpha$) 与假设检验 H_0/H_1 结构。

5. 一元回归: 会推导正规方程并解出 $\hat{a}, \hat{b}$; 会写 Q, S, R^2 。
6. 多元回归: 会写矩阵形式、正规方程、 $\hat{\beta}$ 与 $\hat{\sigma}^2$ 。